

دانشکده ریاضی و کامپیوتر

بخش علوم کامپیوتر

پروژه کارشناسی

بهبود تصاویر کم‌نور در تشخیص اشیا

Low-Light Image Enhancement in Object Detection

دانشجو :یاسین پوررئیسی

استاد راهنما :دکتر مرجان کوچکی رفسنجانی

سال تحصیلی :۱۴۰۵–۱۴۰۶

۱.مقدمه

۱.۱.مقدمه

بینایی ماشین یکی از شاخه‌های مهم هوش مصنوعی است که با هدف استخراج اطلاعات معنادار از تصاویر، در حوزه‌هایی مانند نظارت تصویری، رباتیک و سامانه‌های هوشمند کاربرد دارد. یکی از مسائل مهم این حوزه، تشخیص شیء است که در آن نوع و موقعیت اشیای موجود در تصویر مشخص می‌شود. با پیشرفت یادگیری عمیق، مدل‌هایی مانند YOLO توانایی بالایی در تشخیص سریع اشیا پیدا کرده‌اند؛ بااین‌حال، کیفیت تصاویر ورودی همچنان یکی از عوامل مؤثر بر عملکرد این مدل‌هاست.

تصاویر ثبت‌شده در محیط‌های کم‌نور معمولاً از روشنایی و کنتراست پایینی برخوردارند و ممکن است جزئیات مهم اشیا در آن‌ها به‌خوبی قابل مشاهده نباشد. این شرایط می‌تواند تشخیص صحیح اشیا را دشوار کند. به همین دلیل، بهبود تصاویر کم‌نور به‌عنوان یکی از راهکارهای قابل بررسی برای افزایش کیفیت ورودی سامانه‌های تشخیص شیء مورد توجه قرار گرفته است.

۱.۲.بیان مسئله

مسئله اصلی این پروژه، بررسی تأثیر روش‌های بهبود تصویر بر عملکرد تشخیص اشیا در شرایط کم‌نور است. اگرچه افزایش روشنایی و بهبود کنتراست می‌تواند ظاهر تصاویر را بهتر کند، این تغییرات لزوماً به افزایش دقت تشخیص منجر نمی‌شوند. برخی روش‌ها ممکن است نویز را تقویت کنند یا جزئیات و ویژگی‌های مهم اشیا را تغییر دهند؛ در نتیجه، ارزیابی تأثیر آن‌ها بر عملکرد واقعی آشکارساز ضروری است.

در این پروژه، مجموعه‌داده کم‌نور ExDark [1] و مدل تشخیص شیء YOLOv8 برای بررسی این مسئله انتخاب شده‌اند. چهار روش تصحیح گاما (Gamma Correction) [2]، همسان‌سازی تطبیقی هیستوگرام با محدودیت کنتراست (CLAHE) [3]، روش یادگیری عمیق Zero-DCE [4] و روش SCI [5] برای بهبود تصاویر به کار گرفته شده‌اند. سپس عملکرد تشخیص روی تصاویر اصلی و نسخه‌های بهبودیافته مقایسه می‌شود تا مشخص شود هر روش چه تأثیری بر دقت شناسایی و مکان‌یابی اشیا دارد.

۱.۳.اهمیت و ضرورت موضوع

تشخیص اشیا در شرایط کم‌نور در کاربردهایی مانند نظارت تصویری شبانه، سامانه‌های هوشمند حمل‌ونقل و رباتیک اهمیت دارد. در چنین شرایطی، افت کیفیت تصویر می‌تواند باعث شناسایی نادرست اشیا یا تشخیص‌ندادن برخی از آن‌ها شود. بررسی روش‌های بهبود تصویر می‌تواند به شناخت بهتر محدودیت‌ها و قابلیت‌های این روش‌ها در کاربردهای واقعی کمک کند.

همچنین، مقایسه روش‌های کلاسیک و مبتنی بر یادگیری عمیق از نظر تأثیر بر عملکرد تشخیص، امکان بررسی تفاوت رویکردهای ساده و پیچیده‌تر را فراهم می‌کند. اهمیت این پژوهش در آن است که ارزیابی روش‌ها صرفاً بر اساس ظاهر تصاویر انجام نمی‌شود، بلکه نتایج آن‌ها با معیارهای کمّی تشخیص شیء سنجیده می‌شود.

۱.۴.اهداف پروژه

هدف اصلی این پروژه، بررسی تأثیر روش‌های بهبود تصاویر کم‌نور و آموزش تکمیلی مدل تشخیص شیء بر عملکرد تشخیص اشیا در مجموعه‌داده ExDark است.

در این راستا، چهار روش Gamma Correction ، CLAHE، Zero-DCE و SCI برای بهبود تصاویر بررسی شده‌اند. همچنین، مدل YOLOv8 با استفاده از مجموعه‌داده ExDark فاین‌تیون شده است تا تأثیر آموزش مدل با تصاویر کم‌نور بر عملکرد تشخیص ارزیابی شود.

اهداف جزئی پروژه عبارت‌اند از:

- ارزیابی عملکرد اولیه YOLOv8 روی تصاویر اصلی مجموعه‌داده.ExDark
- بررسی تأثیر چهار روش منتخب بهبود تصویر بر نتایج تشخیص اشیا.
- فاین‌تیون‌کردن YOLOv8 روی مجموعه‌داده ExDark و ارزیابی عملکرد مدل آموزش‌دیده.
- مقایسه نتایج روش‌های بهبود تصویر با عملکرد مدل فاین‌تیون‌شده.
- تحلیل نتایج با استفاده از معیارهایPrecision ، Recall، mAP@50 و mAP@50–95

هدف نهایی، تعیین تأثیر بهبود تصویر و آموزش تکمیلی مدل بر تشخیص اشیا در شرایط کم‌نور و مقایسه نتایج این رویکردها در چارچوب آزمایش‌های انجام‌شده است.

۲.مروری بر کارهای انجام‌شده

روش‌های مرتبط با این پروژه را می‌توان در دو گروه کلی روش‌های کلاسیک بهبود تصویر و روش‌های یادگیری عمیق دسته‌بندی کرد.

۲.۱.روش‌های کلاسیک بهبود روشنایی

روش تصحیح گاما (Gamma Correction) [2]با اعمال یک تبدیل غیرخطی بر شدت پیکسل‌ها، روشنایی تصویر را تغییر می‌دهد. این روش ساده و کم‌هزینه است، اما انتخاب نامناسب پارامتر گاما ممکن است موجب روشن‌شدن بیش از حد بخش‌هایی از تصویر یا کاهش جزئیات شود.

روش همسان‌سازی تطبیقی هیستوگرام با محدودیت کنتراست (CLAHE) [3]با بهبود کنتراست در نواحی کوچک تصویر، می‌تواند جزئیات نواحی تاریک را آشکارتر کند. محدودکردن تقویت کنتراست نیز برای جلوگیری از تقویت بیش از حد برخی تغییرات شدت روشنایی در نظر گرفته شده است. بااین‌حال، عملکرد این روش به ویژگی‌های تصویر و پارامترهای تنظیم‌شده وابسته است.

مزیت اصلی این دو روش، سادگی پیاده‌سازی و هزینه محاسباتی پایین آن‌هاست. با وجود این، بهبود ظاهری تصویر به‌تنهایی تضمین نمی‌کند که عملکرد مدل تشخیص شیء نیز افزایش یابد؛ بنابراین، ارزیابی آن‌ها در کنار معیارهای تشخیص ضروری است.

۲.۲ .روش‌های مبتنی بر یادگیری عمیق

با گسترش یادگیری عمیق، روش‌های جدیدی برای بهبود تصاویر کم‌نور معرفی شده‌اند که به‌جای استفاده صرف از تبدیل‌های ثابت، ویژگی‌های لازم برای تنظیم روشنایی تصویر را با شبکه‌های عصبی یاد می‌گیرند.

Guoو همکاران در سال ۲۰۲۰ روش Zero-DCE [4]را معرفی کردند. این روش با استفاده از یک شبکه عصبی سبک، منحنی‌های تنظیم روشنایی را برای پیکسل‌های تصویر تخمین می‌زند. یکی از ویژگی‌های مهم آن، استفاده از توابع هزینه بدون نیاز به تصاویر مرجع روشن برای آموزش است. نویسندگان این روش، علاوه بر ارزیابی کیفیت تصاویر بهبودیافته، کاربرد بالقوه آن را در تشخیص چهره در شرایط تاریک نیز بررسی کردند.

Ma و همکاران در سال ۲۰۲۲ روش SCI [5]با Self-Calibrated Illumination را برای بهبود تصاویر کم‌نور ارائه کردند. این روش از فرایند یادگیری آبشاری و سازوکار خودکالیبراسیون برای تخمین روشنایی استفاده می‌کند و با هدف دستیابی به بهبود تصویر با هزینه محاسباتی پایین طراحی شده است.

با وجود قابلیت‌های این روش‌ها، کیفیت خروجی آن‌ها به شرایط تصویر ورودی و رفتار مدل وابسته است. ممکن است برخی تصاویر روشن‌تر شوند، اما بخشی از جزئیات یا ویژگی‌های مناسب برای تشخیص اشیا همچنان از دست برود.

ازاین‌رو، در این پروژه Zero-DCE و SCI در کنار روش‌های کلاسیک Gamma Correction و CLAHE بررسی می‌شوند تا تأثیر رویکردهای متفاوت بهبود تصویر قابل مقایسه باشد.

۲.۳ .تشخیص اشیا در تصاویر کم‌نور و مجموعه‌داده ExDark

Loh و Chan در سال ۲۰۱۹ مجموعه‌داده ExDark [1]را برای مطالعه تصاویر کم‌نور و بررسی مسائل بینایی ماشین در این شرایط معرفی کردند. این مجموعه شامل ۷۳۶۳ تصویر در ۱۲ دسته شیء است و تصاویر آن شرایط نوری مختلفی را از محیط‌های بسیار تاریک تا گرگ‌ومیش پوشش می‌دهند.

در پژوهش‌های بعدی، علاوه بر بهبود تصویر پیش از تشخیص، روش‌هایی نیز برای سازگارکردن مدل‌های تشخیص با شرایط کم‌نور بررسی شده‌اند. برای نمونه، برخی پژوهش‌ها از تنظیم معماری آشکارساز، تقویت ویژگی‌ها، افزایش داده و آموزش مدل روی تصاویر کم‌نور استفاده کرده‌اند. یک نمونه از این رویکردها، پژوهش منتشرشده درباره بهبود YOLOv7 [6]در شرایط کم‌نور است که روش‌های تغییر معماری و آموزش را روی ExDark ارزیابی می‌کند.

این مطالعات نشان می‌دهند که مسئله تشخیص اشیا در شرایط کم‌نور را می‌توان از دو جنبه بررسی کرد: بهبود کیفیت تصاویر ورودی و سازگارکردن خود مدل تشخیص با داده‌های هدف. مقایسه این رویکردها با یکدیگر می‌تواند مشخص کند که در شرایط آزمایش یکسان، کدام روش عملکرد مناسب‌تری دارد.

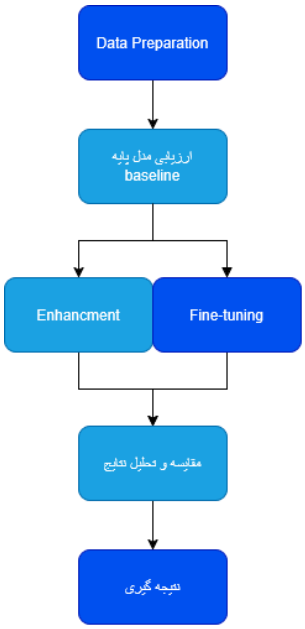
۳.روش پیشنهادی

۳.۱.روند و معماری کلی

به‌طور کلی، معماری پروژه شامل سه مرحله اصلی است :

- ارزیابی مدل پایه روی تصاویر اصلی
- بررسی تأثیر روش‌های مختلف بهبود تصویر
- آموزش تکمیلی مدل تشخیص اشیا

شکل زیر نمای کلی مراحل اجرای پروژه و ارتباط میان آن‌ها را نشان می‌دهد.



۳.۲.دیتاست

در ایـن پـروژه، از مجموعـه‌داده ExDark (Exclusively Dark Image Dataset) [1]اسـتفاده شـده اسـت، مجموعه‌داده ExDark یکی از مجموعه‌داده‌های شناخته‌شده در حوزه بینایی ماشین است که بـه‌طور اختصاصـی بـرای تصاویر ثبت‌شده در شرایط نور کم تهیه شده است .این مجموعه شامل ۷۳۶۳ تصویر در ۱۲ کلاس مختلف از اشیا است . تصاویر آن شرایط نوری متفاوتی مانند نور بسیار کم، تاریکی، نور کم محیط و روشنایی ناشی از منابع نـوری مصـنوعی را پوشش می‌دهند.

۱۲ کلاس موجود در این مجموعه‌داده عبارت‌اند از :دوچرخه، قایق، بطری، اتوبوس، خودرو، گربه، صندلی، فنجان، سـگ، موتورسیکلت، انسان و میز است.

هر تصویر دارای برچسب‌های مربوط به اشیای موجود در آن است که شامل کلاس شیء و مختصات محدوده آن (Bounding Box) می‌شود .این برچسب‌ها امکان آموزش و ارزیابی مدل‌های تشخیص اشیا را فراهم می‌کنند.

در این پروژه، تصاویر و برچسب‌های مجموعه‌داده در قالب مورد نیاز مدل YOLO آماده‌سازی شده و داده‌ها به سه بخش آموزش (Train)، اعتبارسنجی (Validation) و آزمون (Test) تقسیم شده‌اند .

۳.۳.نحوه ارزیابی

برای بررسی عملکرد مدل تشخیص اشیا و مقایسه نتایج آزمایش‌های مختلف، از معیارهای استاندارد ارزیابی در حوزه تشخیص اشیا استفاده شده است.

معیارهای ارزیابی[7] مورد استفاده عبارت‌اند از:

- Precision : نسبت تشخیص‌های صحیح به کل تشخیص‌های مثبت
- Recall : نسبت اشیای صحیح شناسایی‌شده به کل اشیای واقعی موجود در تصاویر
- mAP@50 : میانگین دقت متوسط مدل در آستانه اشتراک بر اجتماع (IoU) برابر با ۰٫۵
- mAP@50-95 : میانگین دقت متوسط در آستانه‌های IoU از ۰٫۵ تا ۰٫۹۵ با گام ۰٫۰۵

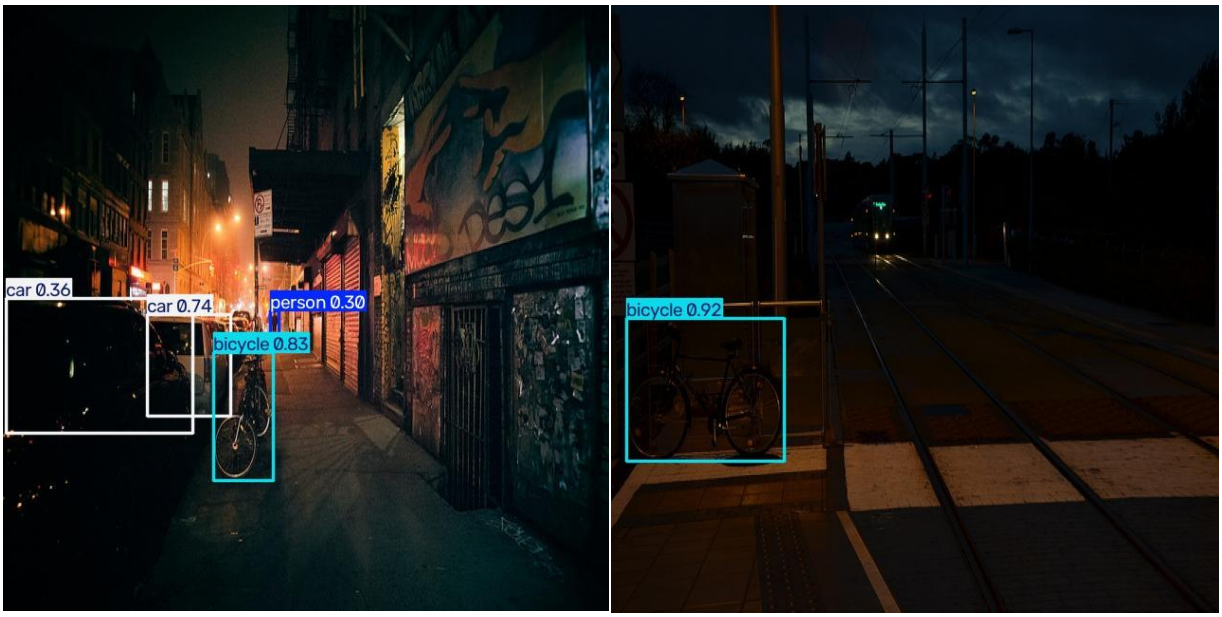
۳.۴.مدل پایه (Baseline)

در نخستین مرحله، عملکرد مدل YOLOv8n [8]روی تصاویر اصلی مجموعه‌داده ExDark و بدون اعمال هیچ‌گونه روش بهبود تصویر یا آموزش تکمیلی بررسی شد .این وزن‌ها پیش‌تر روی مجموعه‌داده COCO [9]آموزش دیده‌اند.

از آنجا که مدل اولیه روی مجموعه‌داده COCO آموزش دیده است، خروجی کلاس‌های آن مستقیماً با کلاس‌های ExDark مطابقت ندارد .بنابراین، ابتدا کلاس‌های مشترک میان دو مجموعه‌داده شناسایی و شناسه کلاس‌های COCO به شناسه متناظر در ExDark تبدیل شدند و اندازه ورودی تصاویر برای مدل برابر با ۶۴۰ پیکسل با batch size ۴ در نظر گرفته شد.

نتایج :

mAP@50	mAP@50-95	Precision	Recall
0.4813	0.2590	0.6575	0.4380



۳.۵.بهبود تصویر (Enhancment)

تصاویر بخش آزمون مجموعه‌داده به‌صورت جداگانه با هر یک از روش‌ها پردازش شدند .سپس تصاویر حاصل، بدون تغییر در وزن‌های مدل تشخیص، به همان مدل YOLO ازپیش‌آموزش‌دیده داده شدند.

۳.۵.۱.روش Gamma Correction

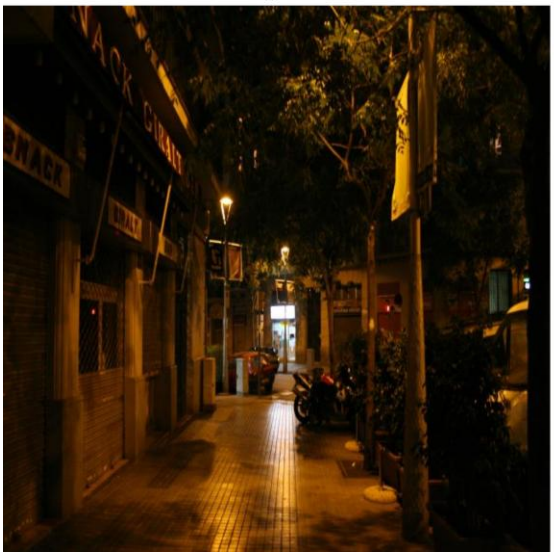
روش Gamma Correctionیکی از روش‌های ساده و متداول برای تنظیم روشنایی تصاویر است .در این روش، شدت روشنایی پیکسل‌ها با استفاده از یک تابع توانی تغییر می‌کند .با انتخاب مقدار مناسب پارامتر گاما می‌توان روشنایی تصویر را افزایش یا کاهش داد.

در این پروژه، برای روشن‌تر کردن تصاویر کم‌نور از مقدار گامای ۱.۵ استفاده شده است.

نتایج :

mAP@50	mAP@50-95	Precision	Recall
0.4102	0.2148	0.6539	0.3587

Original



Gamma



۳.۵.۲.روش CLAHE

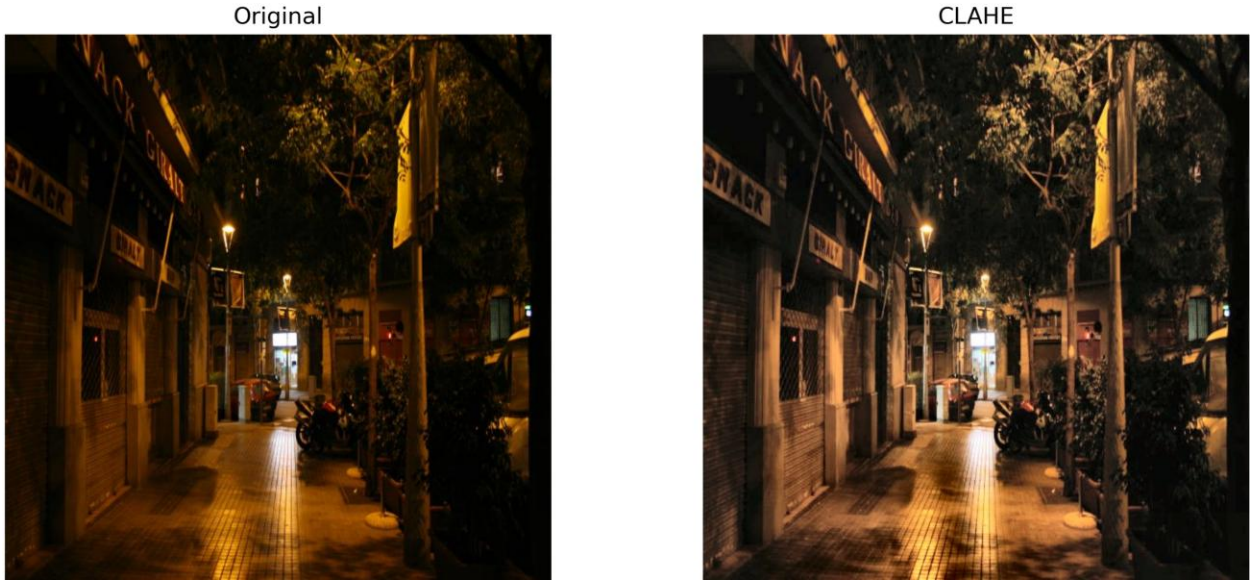
روش CLAHE مخفف Contrast Limited Adaptive Histogram Equalization است و یکی از روش‌های بهبود کنتراست محلی تصاویر محسوب می‌شود.

در این روش، تصویر به نواحی کوچک‌تری تقسیم می‌شود و عملیات همسان‌سازی هیستوگرام برای هر ناحیه به‌صورت جداگانه انجام می‌گیرد. که در این آزمایش، تصویر به شبکه‌ای با ابعاد ۸ در ۸ تقسیم شده است.

CLAHE با محدود کردن میزان تقویت کنتراست، از افزایش بیش از حد نویز در نواحی مختلف تصویر جلوگیری می‌کند.

نتایج :

mAP@50	mAP@50-95	Precision	Recall
0.4128	0.2202	0.6370	0.3665



۳.۵.۳.روش Zero-DCE

روش Zero-DCE یکی از روش‌های مبتنی بر یادگیری عمیق برای بهبود تصاویر کم‌نور است و با استفاده از یک شبکه عصبی، منحنی‌های تنظیم روشنایی را به‌صورت تطبیقی تخمین می‌زند.

ایده اصلی این روش، بهبود روشنایی تصاویر بدون نیاز به تصاویر مرجع روشن و متناظر است .به همین دلیل، این روش در دسته روش‌های یادگیری بدون نظارت یا Zero-Reference قرار می‌گیرد.

مدل Zero-DCE چند خروجی تولید می‌کند که شامل تصویر بهبودیافته میانی، تصویر بهبودیافته نهایی و نقشه‌های منحنی روشنایی است .در این پروژه، خروجی نهایی شبکه برای ادامه آزمایش‌ها انتخاب و ذخیره شده است.

نتایج :

mAP@50	mAP@50-95	Precision	Recall
0.2941	0.1522	0.6157	0.2509

Original



Zero-DCE



۳.۵.۴.روش SCI

روش SCI یا Self-Calibrated Illumination یکی دیگر از روش‌های مبتنی بر یادگیری عمیق برای بهبود تصاویر کم‌نور است .این روش با تمرکز بر تخمین و تنظیم روشنایی تصویر، تلاش می‌کند کیفیت تصاویر کم‌نور را بهبود دهد.

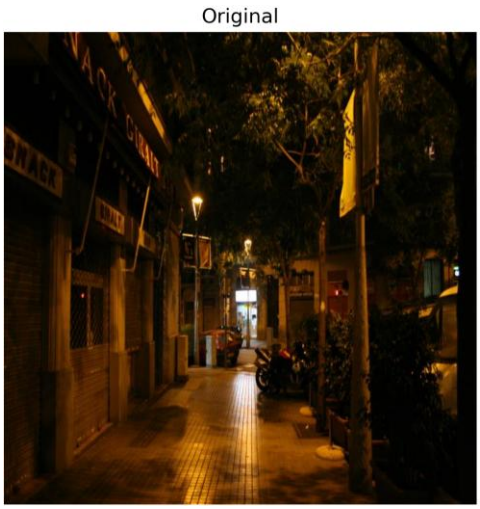
در این روش، شبکه عصبی اطلاعات مربوط به روشنایی تصویر را استخراج کرده و از آن برای تولید نسخه بهبودیافته استفاده می‌کند .یکی از ویژگی‌های SCI ، طراحی نسبتاً سبک آن و تلاش برای کاهش پیچیدگی محاسباتی فرایند بهبود تصویر است.

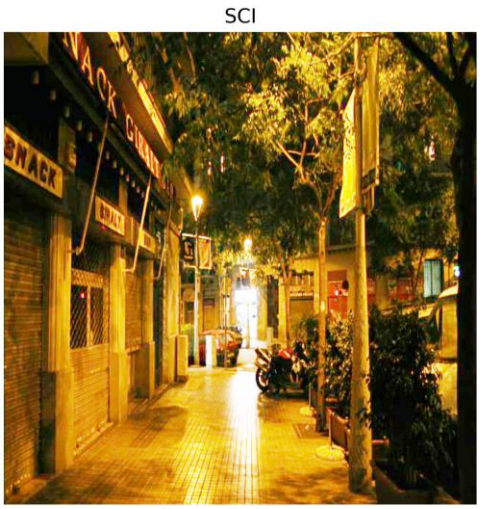
در این پروژه، از پیاده‌سازی اصلی روش SCI و وزن‌های ازپیش‌آموزش‌دیده استفاده شده است .ابتدا مدل بارگذاری و در حالت ارزیابی قرار گرفت .سپس تصاویر ورودی به Tensor تبدیل شده و به شبکه داده شدند.

مدل SCI دو خروجی اصلی تولید می‌کند که شامل نقشه روشنایی (Illumination Map) و تصویر بهبودیافته است . در این پروژه، خروجی دوم شبکه، یعنی تصویر بهبودیافته، برای ادامه پردازش انتخاب شده است.

نتایج :

mAP@50	mAP@50-95	Precision	Recall
0.2975	0.1534	0.6040	0.2609





Fine-tuning.۳.۶

در مراحل قبلی، عملکرد مدل YOLOv8n با وزن‌های ازپیش‌آموزش‌دیده روی تصاویر اصلی و تصاویر بهبودیافته بررسی شد .در این مرحله، به‌منظور سازگار کردن مدل با ویژگی‌های تصاویر کم‌نور مجموعه‌داده ExDark، فرایند آموزش تکمیلی(Fine-tuning) انجام شد.

داده‌ها در سه بخش آموزش (Train) ، اعتبارسنج (Validation) و آزمون (Test) سازمان‌دهی شدند .تصاویر بخش آموزش برای به‌روزرسانی وزن‌های مدل استفاده شدند .بخش اعتبارسنجی برای بررسی عملکرد مدل در طول آموزش و انتخاب بهترین وزن‌ها در نظر گرفته شد .در نهایت، بخش آزمون برای ارزیابی عملکرد مدل پس از پایان آموزش مورد استفاده قرار گرفت.

پارامترهای مورد استفاده مطابق زیر است :

Epochs	Image Size	Batch Size	Optimizer	Pretrained
50	640 × 640	8	Auto	True

پس از آماده‌سازی داده‌ها و تعیین پارامترهای آموزش، مدل با استفاده از تصاویر اصلی بخش آموزش مجموعه‌داده ExDark آموزش داده شد .در طول فرایند، وزن‌های مدل به‌صورت تدریجی به‌روزرسانی شدند و عملکرد آن روی مجموعه اعتبارسنجی مورد بررسی قرار گرفت.

پس از پایان آموزش، مدل Fine-tuned روی تصاویر بخش آزمون مجموعه‌داده ExDark اجرا شد.

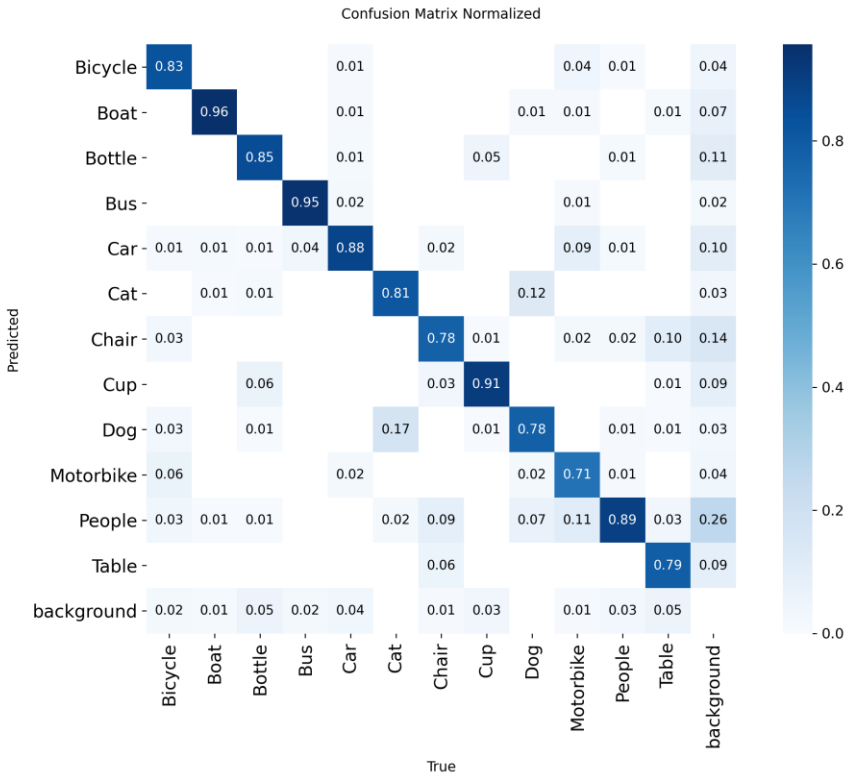
نتایج :

mAP@50	mAP@50-95	Precision	Recall
0.7170	0.4488	0.6469	0.7059

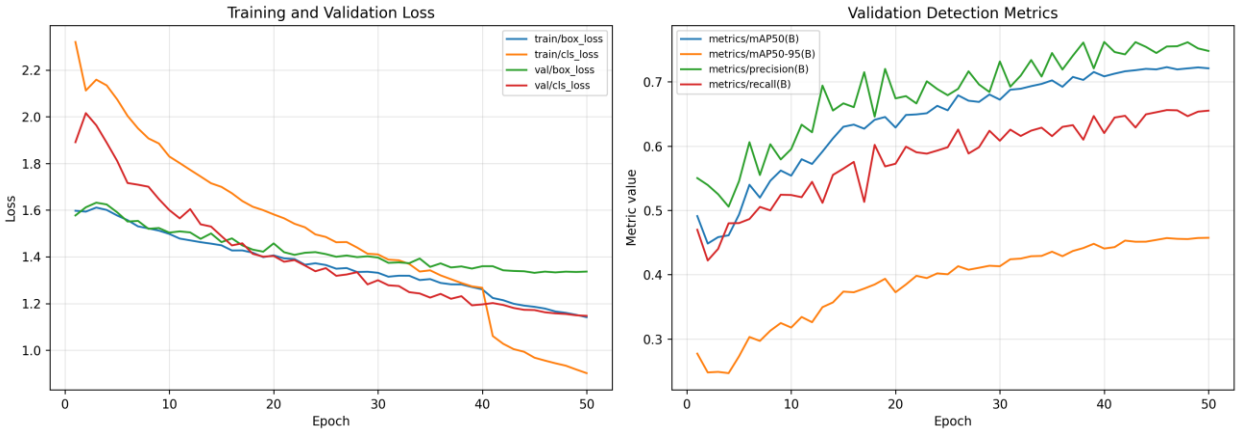


Baseline vs Fine-tuned

همان‌طور که در شکل بالا مشاهده می‌شود، مدل Fine-tuned در مقایسه با مدل پایه (Baseline) عملکرد بهتری در تشخیص برخی از اشیا داشته است. برای مثال، در تصویر اول، مدل پایه موفق به شناسایی موتورسیکلت نشده است؛ درحالی‌که مدل Fine-tuned توانسته آن را به‌درستی تشخیص دهد. همچنین، در تصویر دوم، مدل پایه شیء متعلق به کلاس سگ را به‌اشتباه گربه تشخیص داده است، اما مدل Fine-tuned توانسته کلاس آن را به‌درستی شناسایی کند.



Confusion matrix normalized



Training curve

۴.مقایسه و تحلیل نتایج

Method	*mAP@50*	*mAP@50-95*	*Precision*	*Recall*
Baseline	**0.4813**	**0.2590**	**0.6575**	**0.4380**
Gamma	**0.4102**	**0.2148**	**0.6539**	**0.3587**
CLAHE	**0.4128**	**0.2202**	**0.6370**	**0.3665**
Zero-DCE	**0.2941**	**0.1522**	**0.6157**	**0.2509**
SCI	**0.2975**	**0.1534**	**0.6040**	**0.2609**
Fine-Tune	**0.7170**	**0.4488**	**0.6469**	**0.7059**

۴.۱.نتایج روش های بهبود تصویر

بر اساس نتایج به‌دست‌آمده، استفاده مستقیم از روش‌هایGamma Correction ، CLAHE، Zero-DCEو SCI در آزمایش حاضر نتوانسته است عملکرد مدل پایه YOLOv8n را بهبود دهد. در میان این روش‌ها، Gamma Correctionو CLAHE افت کمتری ایجاد کرده‌اند؛ در حالی که Zero-DCE و SCI کاهش بیشتری در معیارهای تشخیص داشته‌اند.

از دلایل احتمالی این افت عملکرد میتواند این باشد که در فرایند بهبود تصویر ممکن است برخی جزئیات ظریف، بافت‌ها یا مرزهای اشیا تغییر کنند. همچنین، تغییرات ایجادشده در روشنایی و کنتراست ممکن است توزیع ویژگی‌های ورودی مدل را تغییر دهد و یا باعث افزایش نویز تصویر شود.

۴.۲.نتیجه مدل Fine-tuned

برخلاف روش‌های قبلی که تنها تصاویر ورودی را تغییر می‌دادند، در این مرحله مدل YOLOv8n با استفاده از تصاویر اصلی مجموعه‌داده ExDark آموزش تکمیلی داده شده است. هدف از این کار، سازگارکردن ویژگی‌های آموخته‌شده مدل با شرایط نوری و ظاهری تصاویر این مجموعه‌داده بوده است.

نتایج نشان می‌دهد که آموزش تکمیلی تأثیر قابل‌توجهی بر عملکرد مدل داشته است. مقدار mAP@50 از 0.4813 در مدل پایه به 0.7170 در مدل Fine-tuned افزایش یافته است. همچنین mAP@50–95 از 0.2590 به 0.4488 رسیده است. این تغییرات نشان می‌دهند که مدل پس از آموزش تکمیلی، نه‌تنها در تشخیص صحیح اشیا عملکرد بهتری داشته، بلکه در معیار سخت‌گیرانه‌تر mAP@50–95 نیز بهبود قابل‌توجهی نشان داده است.

مهم‌ترین تغییر در معیار Recall مشاهده می‌شود. این معیار از 0.4380 به 0.7059 افزایش یافته است. افزایش Recallنشان می‌دهد که مدل آموزش‌دیده توانسته است تعداد بیشتری از اشیای موجود در تصاویر را شناسایی کند و موارد کمتری را از دست بدهد.

دلیل احتمالی بهبود عملکرد مدل را می‌توان در سازگاری آن با دامنه داده‌های هدف (Domain Adaptation) جست‌وجو کرد. وزن‌های اولیه YOLOv8n روی مجموعه‌داده COCO آموزش دیده‌اند؛ در حالی که تصاویر ExDarkاز نظر شرایط نورپردازی، میزان روشنایی، کنتراست و ویژگی‌های ظاهری با تصاویر معمول این مجموعه‌داده تفاوت دارند. آموزش تکمیلی روی تصاویر اصلی ExDark به مدل امکان داده است تا ویژگی‌های مرتبط با اشیا را در شرایط کم‌نور بهتر یاد بگیرد و پارامترهای خود را با توزیع داده‌های هدف سازگار کند.

۴.۳.نتیجه گیری نهایی

بر اساس نتایج به‌دست‌آمده، استفاده مستقیم از روش‌هایGamma Correction ، CLAHE، Zero-DCE و SCI در آزمایش حاضر نتوانسته است عملکرد مدل پایه YOLO را بهبود دهد. در میان این روش‌ها، Gamma

Correctionو CLAHE افت کمتری ایجاد کرده‌اند؛ در حالی که Zero-DCE و SCI کاهش بیشتری در معیارهای تشخیص داشته‌اند.

در مقابل، آموزش تکمیلی YOLO با استفاده از تصاویر اصلی مجموعه‌داده ExDark موجب افزایش قابل‌توجه mAP و Recall شده است. این نتیجه نشان می‌دهد که در شرایط آزمایش حاضر، سازگارکردن مدل تشخیص با ویژگی‌های تصاویر کم‌نور مؤثرتر از اعمال مستقل روش‌های بهبود تصویر بوده است.

در مجموع، نتایج این پروژه بر اهمیت توجه به هدف نهایی پردازش تصویر تأکید دارند. **بهبود ظاهری تصویر به‌تنهایی معیار مناسبی برای ارزیابی موفقیت یک روش در کاربردهای تشخیص شیء نیست؛** بلکه باید تأثیر آن بر عملکرد مدل تشخیص نیز به‌صورت کمی بررسی شود.

منابع

[1] Loh, Y. P., & Chan, C. S. (2019). Getting to Know Low-light Images with the Exclusively Dark (ExDark) Dataset. *Computer Vision and Image Understanding, 178*, 30–42. https://doi.org/10.1016/j.cviu.2018.10.010

[2] Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). Pearson.

[3] Zuiderveld, K. (1994). Contrast Limited Adaptive Histogram Equalization. In P. S. Heckbert (Ed.), *Graphics Gems IV* (pp. 474–485). Academic Press. https://doi.org/10.1016/B978-0-12-336156-1.50061-6

[4] Guo, C., Li, C., Guo, J., Loy, C. C., Hou, J., Kwong, S., & Cong, R. (2020). Zero-Reference Deep Curve Estimation for Low-Light Image Enhancement. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 1777–1786). https://doi.org/10.1109/CVPR42600.2020.00185

[5] Ma, L., Ma, T., Liu, R., Fan, X., & Luo, Z. (2022). Toward Fast, Flexible, and Robust Low-Light Image Enhancement. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 5637–5646). https://doi.org/10.1109/CVPR52688.2022.00555

[6] Zhao, D., Shao, F., Zhang, S., Yang, L., Zhang, H., Liu, S., & Liu, Q. (2024). Advanced Object Detection in Low-Light Conditions: Enhancements to YOLOv7 Framework. *Remote Sensing, 16*(23), 4493. https://doi.org/10.3390/rs16234493

[7] Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. (2010). The Pascal Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision, 88*, 303–338. https://doi.org/10.1007/s11263-009-0275-4

[8] Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8* [Computer software]. GitHub. https://github.com/ultralytics/ultralytics

[9] Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common Objects in Context. In *Computer Vision – ECCV 2014* (pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48

[10] Pourraisi, Y. (2026). *Low-Light Image Enhancement for Object Detection: Bachelor's Project Repository* [Source code, Google Colab notebooks, experimental results, and project report]. GitHub. https://github.com/yasinpurraisi/Low-Light-Enhancment-in-Object-Detection